

Practica 5: XAI - Partial Dependence Plots

Alejandro Legleye

06/05/2026

Contents

1	Introduccion	1
2	PDP 1D: prediccion de alquileres de bicicletas	1
3	PDP 2D: humedad y temperatura	2
4	PDP: prediccion del precio de viviendas	3
5	Conclusiones	4

1 Introduccion


El objetivo de esta practica es aplicar metodos explicables independientes del modelo. En concreto, se usan Partial Dependence Plots (PDP) para analizar como cambia la prediccion media de un random forest cuando se fuerza una variable a tomar distintos valores.

Un PDP no muestra una relacion causal: muestra la relacion aprendida por el modelo manteniendo el resto de variables segun la distribucion observada. Por eso es util para interpretar modelos no lineales, pero debe leerse como una explicacion del modelo y no como una ley directa del fenomeno real.

2 PDP 1D: prediccion de alquileres de bicicletas

Se ajusta un random forest de regresion para predecir `cnt`, el numero total de bicicletas alquiladas por dia. Se eliminan `casual` y `registered` porque son componentes directos de `cnt` y producirian fuga de informacion. La varianza explicada OOB aproximada del modelo es 88.5%.

PDP 1D para el modelo de alquileres de bicicletas




Interpretación. El paso de los días desde 2011 tiene un efecto creciente: el modelo aprende una tendencia temporal positiva, coherente con una mayor demanda en la segunda parte del periodo observado. La temperatura también tiene un efecto claramente positivo hasta valores medios-altos; con temperaturas más agradables el modelo predice más alquileres.


La humedad muestra el patrón contrario: al aumentar, especialmente en niveles altos, la predicción media de bicicletas baja. El viento también reduce la demanda predicha cuando alcanza valores altos, aunque su efecto es menos fuerte y más irregular que el de la temperatura o la humedad.

3 PDP 2D: humedad y temperatura

Para el PDP bidimensional se usa una muestra aleatoria de 500 observaciones, como indica el enunciado, y se calcula la predicción media para cada combinación de temperatura y humedad.



PDP 2D: temperatura y humedad




Interpretacion. La zona con mayor prediccion aparece con temperatura media o alta y humedad baja o moderada. Cuando la humedad es elevada, el numero predicho de alquileres cae incluso si la temperatura es favorable. Esto indica que el modelo no solo aprende efectos individuales, sino tambien una interaccion intuitiva: los dias calidos favorecen el alquiler, pero si van acompañados de mucha humedad la demanda esperada disminuye.

Las densidades marginales ayudan a distinguir donde hay datos reales. Las zonas del mapa con poca densidad deben interpretarse con mas cautela, porque el modelo esta extrapolando mas que en las regiones frecuentes.

4 PDP: prediccion del precio de viviendas

Para el precio de las viviendas se entrena un random forest con las variables indicadas por el enunciado: bedrooms, bathrooms, sqft_living, sqft_lot, floors y yr_built. La varianza explicada OOB

aproximada del modelo es 62%. Para calcular los PDP se usa una muestra de 2000 observaciones, reduciendo el coste computacional sin cambiar la logica del metodo.



Interpretacion. La variable con efecto mas claro es `sqft_living`: a mayor superficie habitable, mayor precio predicho. Este patron es esperable porque el tamaño interior es una de las senales mas directas del valor de una vivienda.

Los banos tambien incrementan el precio predicho, aunque con tramos de meseta. Esto sugiere que el modelo valora mas pasar de pocos banos a una dotacion media que anadir banos cuando la vivienda ya tiene varios. Los dormitorios muestran un efecto menos lineal: mas dormitorios no siempre implican mayor precio si no vienen acompanados de mas superficie u otras caracteristicas. Las plantas presentan un efecto moderado e irregular; el modelo parece asociarlas con cierto aumento de precio, pero no con una relacion tan fuerte como la superficie habitable.

5 Conclusiones

Los PDP permiten resumir de forma visual la relacion aprendida por modelos de random forest. En el caso de las bicicletas, la temperatura y la tendencia temporal elevan la prediccion, mientras que humedad y viento altos la reducen. En el caso de las viviendas, la superficie habitable domina la explicacion del precio, seguida por los banos; dormitorios y plantas tienen efectos mas dependientes del contexto.

La principal precaucion es que los PDP promedian sobre todas las observaciones: si hay variables muy correlacionadas o zonas con pocos datos, la interpretacion debe hacerse con cautela.